

DEEP LEARNING CLIP

О чем


- **Мотивация**
 - Почему OpenAI создали CLIP (Contrastive Language-Image Pre-training)
- **Обзор подхода**
- **Архитектура модели**
 - Кодировщик текста и изображений
 - Объединенное пространство эмбедингов
 - Функция потерь
- **Детали набора данных и обучения**
- **Zero-shot**
- **Заключение**

Мотивация

Середина 2020 года

- Ограничения традиционных моделей машинного зрения с учителем
 - фиксированные наборы меток
 - обучение, привязанное к конкретному набору данных
- Контроль с помощью естественного языка предоставляет масштабируемый и богатый источник обучающих данных
 - Появились Transformer, BERT, GPT-3, NLP переживал свой расцвет
 - Вместо сбора/аннотирования меток — получение текстового описания, связанного с каждым изображением
- Цель: обучение переносимым визуальным представлениям без массивных ручных аннотаций

Обзор подхода CLIP



- Обучение общему пространству вложений для изображений и текста.
 - Прогресс в области обработки текста
 - Как это можно применить к обработке изображений?
- Совместное обучение кодировщика изображений и кодировщика текста на 400 млн пар (изображение, текст).
 - Большие пары данных, которые легче получить, вместо утомительной ручной маркировки
 - Совместное обучение с использованием контрастивного обучения
- Обеспечивает обучение без предварительного обучения (zero-shot learning) за счет использования естественного языка для описания задач

Архитектура CLIP — двойной кодировщик

- Два основных компонента
 - Кодировщик изображений: может представлять собой модифицированную сеть ResNet (например, RN50, RN101) или Vision Transformer (ViT)
 - Кодировщик текста: Transformer (с модификациями, такими как токенизация с использованием кодирования пар байтов (BPE))



- Оба выходных сигнала линейно проецируются в общее мультимодальное пространство вложений.

Детали декодирования изображений

- Модификация ResNet

- Замена пулинга глобального усреднения пулингом с вниманием, пулинг с сглаживанием для устранения aliasing

- Альтернатива: Vision Transformer с дополнительной нормализацией слоя

- Акцент на масштабируемости и вычислительной эффективности.

Детали декодирования текста

- Архитектура Transformer: 12 слоёв, 63 млн параметров, 8 голов внимания.
 - GPT-3: 96 слоёв, 175 млрд параметров, 96 головок внимания, размер скрытого пространства 12 288, окно контекста токена 2 048, обучение на 570 ГБ текстовых данных.
- Обработывает текст в нижнем регистре, токенизированный по BPE (размер словаря $\approx 49\,152$).
- Использует представление токенов [EOS], которое нормализуется по слоям и линейно проецируется

Общее мультимодальное пространство вложений (эмбедингов)

- Оба кодировщика генерируют векторы признаков, нормализованные по L2.
- Линейная проекция отображает эти признаки в общее пространство вложений.
- Косинусное сходство (масштабированное с помощью обученного параметра температуры) измеряет совместимость изображения и текста.

Цель предварительного обучения – контрастивное обучение

- Контрастивная функция потерь: сопоставить правильные пары «изображение–текст» и отделить неправильные.

Cosine Similarity = $\cos(\theta) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$

Expanded Form:

$$\cos(\theta) = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \cdot \sqrt{\sum_{i=1}^n b_i^2}}$$

Where: - $\mathbf{a} = (a_1, a_2, \dots, a_n)$ and $\mathbf{b} = (b_1, b_2, \dots, b_n)$ are n-dimensional vectors. - $\mathbf{a} \cdot \mathbf{b}$ represents the dot product:

$$\mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i b_i$$

- $\|\mathbf{a}\|$ and $\|\mathbf{b}\|$ are the Euclidean norms (magnitudes):

$$\|\mathbf{a}\| = \sqrt{\sum_{i=1}^n a_i^2}, \quad \|\mathbf{b}\| = \sqrt{\sum_{i=1}^n b_i^2}$$

$$\hat{f}_I(I_i) = \frac{f_I(I_i)}{\|f_I(I_i)\|}$$

$$\hat{f}_T(T_i) = \frac{f_T(T_i)}{\|f_T(T_i)\|}$$

$$S_{ij} = \hat{f}_I(I_i) \cdot \hat{f}_T(T_j)$$

$$S_{ij} = \frac{\hat{f}_I(I_i) \cdot \hat{f}_T(T_j)}{\tau}$$

****Image-to-Text Contrastive Loss:****

$$L_{\text{image}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{ii})}{\sum_{j=1}^N \exp(S_{ij})}$$

****Text-to-Image Contrastive Loss:****

$$L_{\text{text}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{ii})}{\sum_{j=1}^N \exp(S_{ji})}$$

****Final CLIP Loss:****

$$L_{\text{CLIP}} = \frac{1}{2} (L_{\text{image}} + L_{\text{text}})$$

- В партии из N пар существует N² возможных сравнений.
- Используется симметричная функция потерь на основе кросс-энтропии для прогнозирования «изображение → текст» и «текст → изображение»

Псевдо код и функция потерь

```
# image_encoder - ResNet or Vision Transformer
# text_encoder  - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l]       - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t            - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss   = (loss_i + loss_t)/2
```

****Image-to-Text Contrastive Loss:****

$$L_{\text{image}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{ii})}{\sum_{j=1}^N \exp(S_{ij})}$$

****Text-to-Image Contrastive Loss:****

$$L_{\text{text}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(S_{ii})}{\sum_{j=1}^N \exp(S_{ji})}$$

****Final CLIP Loss:****

$$L_{\text{CLIP}} = \frac{1}{2}(L_{\text{image}} + L_{\text{text}})$$

Данные для обучения и аугментация

- Используется 400 миллионов пар (изображение-текст), собранных из Интернета.
- Простое расширение изображений: случайное кадрирование в форме квадратов на изображениях, размер которых был изменен.
- Разнообразные подписи на естественном языке обеспечивают контроль, выходящий за рамки фиксированных меток.


Детали обучения и рекомендации

- Оптимизатор: Adam с разделенными параметрами затухания весов и косинусной кривой изменения скорости обучения.
- Очень большой размер мини-партии (например, 32 768) и обучение со смешанной точностью.
- Масштабируемость для различных моделей (RN50, RN50x16, варианты ViT) для обеспечения высокой вычислительной эффективности.


Zero-shot и промпт инжиниринг

- Классификация без предварительного обучения: генерация текстовых вложений для названий классов или их описаний.
- Использование шаблонов подсказок, таких как «Фотография {label}», для предоставления контекста.
- Обеспечение конкурентоспособной производительности без обучения на конкретном наборе данных.

(2) Create dataset classifier from label text



(3) Use for zero-shot prediction



Ключевые преимущества

- Масштабируемость: эффективное обучение на огромных наборах данных с использованием контрастивного обучения
- Гибкость: способность к обобщению между задачами с помощью переноса знаний без предварительного обучения
- Устойчивость: более эффективная адаптация к сдвигам распределения по сравнению с традиционными моделями с учителем

Сравнение с предыдущими подходами и влияние

- Сравнение с традиционным обучением с учителем на наборе ImageNet и предыдущими подходами «zero-shot» (например, Visual N-Grams)
- Значительное повышение точности при обучении «zero-shot» (например, результаты на ImageNet)
- Более широкое влияние: определение направления будущих исследований в области мультимодального обучения и переноса знаний «zero-shot»

	Dataset Examples	ImageNet ResNet101	Zero-Shot CLIP	Δ Score
ImageNet		76.2	76.2	0%
ImageNetV2		64.3	70.1	+5.8%
ImageNet-R		37.7	88.9	+51.2%
ObjectNet		32.6	72.3	+39.7%
ImageNet Sketch		25.2	60.2	+35.0%
ImageNet-A		2.7	77.1	+74.4%

Ограничения

«На большинстве этих наборов данных производительность данной базовой модели в настоящее время значительно уступает современному уровню развития технологии. Еще предстоит проделать значительную работу по улучшению способностей CLIP к обучению задачам и переносу знаний. Хотя масштабирование до сих пор стабильно улучшало производительность и указывает путь для дальнейшего совершенствования, мы оцениваем, что для достижения CLIP с zero-shot общего уровня передовых технологий требуется примерно 1000-кратное увеличение вычислительной мощности. Обучение с использованием текущего оборудования является невыполнимым. Потребуются дальнейшие исследования по улучшению вычислительной эффективности и эффективности использования данных CLIP».

