


RL: CrossEntropy


Метод crossentropy


Инициализировать политику


Повторить:


- Сыграть $N[100]$ сессий
- Выбрать $M[25]$ лучших сессий, называемых элитными сессиями
- Изменить политику таким образом, чтобы приоритет отдавался действиям с элитных сессий





























Метод табличной кроссэнтропии

- ❑ Политика – это матрица

$$\pi(a|s) = A_{s,a}$$

- ❑ Сыграть N игр с этой политикой
- ❑ Получить M лучших сессий (элитных)

$$elite = [(s_0, a_0), (s_1, a_1), \dots, (s_k, a_k)]$$

Метод табличной кроссэнтропии

- ❑ Политика – это матрица

$$\pi(a|s) = A_{s,a}$$

- ❑ Сыграть N игр с этой политикой
- ❑ Получить M лучших сессий (элитных)
- ❑ Объединить по состояниям

$$\pi(a|s) = \frac{\sum_{s_t, a_t \in Elite} [s_t = s][a_t = a]}{\sum_{s_t, a_t \in Elite} [s_t = s]}$$

Среды с бесконечным/большим пространством состояний



Приближенный метод кроссэнтропии

- Политика аппроксимирована

- Нейронная сеть предсказывает $\pi(a|s)$ при заданном s

- Линейная регрессия, деревья решений и т.д.

- Невозможно установить $\pi(a|s)$ в явном виде

- M лучших сессий (элитных)

$$elite = [(s_0, a_0), (s_1, a_1), \dots, (s_k, a_k)]$$

Приближенный метод кроссэнтропии

Нейронная сеть предсказывает $\pi(a|s)$ при заданном s

M лучших сессий (элитных)

$$elite = [(s_0, a_0), (s_1, a_1), \dots, (s_k, a_k)]$$

Максимизируем правдоподобие действий в лучших играх

$$\pi = \operatorname{argmax}_{\pi} \sum_{s_i, a_i \in Elite} \log \pi(a_i | s_i)$$

Приближенный метод кроссэнтропии

- Инициализировать веса

- Цикл:

Сэмплируем N сессий

$$elite = [(s_0, a_0), (s_1, a_1), \dots, (s_k, a_k)]$$

$$w_{i+1} = w_i + \alpha \nabla \left[\sum_{s_i, a_i \in Elite} \log \pi_{w_i}(a_i | s_i) \right]$$